



Convolutional Neural Networks

El NeoCognitrón Convolutacional

Hubel & Wiesel



Hubel & Wiesel, 1968



Photo from the Nobel Foundation archive.
David H. Hubel




Photo from the Nobel Foundation archive.
Torsten N. Wiesel



Hubel & Wiesel, 1962

Hubel & Wiesel




Photo from the Nobel Foundation archive.

David H. Hubel




Photo from the Nobel Foundation archive.

Torsten N. Wiesel




Hubel & Wiesel, 1962

Hubel & Wiesel





- S-Cells: Simple cells, line detectors.
- C-Cells: motion detectors or aggregators.

Neocognitron




Neocognitron



LeNet 1989

- Defined by convolution operation
- Trained by back propagation
- LeNet-5 (1998) 0.95 % on MNIST (equal to SVM :)



Convolución Matemática

Convolución Matemática

- Es una operación lineal
- Suponiendo que $x(t)$ es una señal unidimensional en función del tiempo y $w(t)$ es un **núcleo** de convolución,
- $s(t) = \int x(k)w(t - k)dk$
- $s(t) = (x * w)(t) = \langle x(k), w^*(t - k) \rangle$, donde $*$ es el conjugado.
- (Correlación $s(t) = \int x(k)w(t + k)dk$ (+ positivo))

Convolución Discreta

- $s[n] = \sum_k x[k]w[n - k]$

Convolución Matemática

Convolución

- La convolución matemática cumple un rol primordial en el procesamiento de señales digitales. Por ejemplo, cualquier filtro digital lineal puede representarse por una igualdad basada en convoluciones discretas.

CCDE - Constant Coefficient Difference Equation


- $\sum_{k=0}^{N-1} w_1[k]y[n-k] = \sum_{k=0}^{M-1} w_2[k]x[n-k]$
- $Y(z) = H(z)X(z)$
- w_1, w_2 son kernels de convolución, x, y son señales discretas.
- X, Y son los estados del sistema y H es la función de transferencia.

Convolución Matemática

Moving Average

```
windowlength = 10  
avgeeg = np.convolve(signal,  
    np.ones((windowlength,))/windowlength,  
    mode='same')
```


Convolución Matemática



Convolución Matemática

Padding

- valid
- same
- full

```
windowlength = 10  
avgeeg = np.convolve(signal,  
    np.ones((windowlength,))/windowlength,  
    mode='same')
```


Convolución Matemática

Padding

Señal discreta $[1, 2, -5, 4, 2, -1]$, con un kernel $[-1, 2, -1]$:

Valid

$[8, -16, 11, 1]$

Same

$[0, 8, -16, 11, 1, -4]$

Full

$[-1, 0, 8, -16, 11, 1, -4, 1]$

Padding

Señal discreta $[1, 2, -5, 4, 2, -1]$, con un kernel $[-1, 2, -1]$:

Valid

$[8, -16, 11, 1]$

Same

$[0, 8, -16, 11, 1, -4]$

Full

$[-1, 0, 8, -16, 11, 1, -4, 1]$

Padding

Señal discreta $[1, 2, -5, 4, 2, -1]$, con un kernel $[-1, 2, -1]$:

Valid

$[8, -16, 11, 1]$

Same

$[0, 8, -16, 11, 1, -4]$

Full

$[-1, 0, 8, -16, 11, 1, -4, 1]$

Convolución Matemática

Convolución bidimensional


$$\begin{aligned} S(i, j) &= (I * k)(i, j) = \sum_m \sum_n I(m, n) K(i - m, j - n) \\ &= \sum_m \sum_n I(i - m, j - n) K(m, n) \end{aligned}$$

Filtrado por Núcleos de Convolución

La operación de filtrado básica en Visión por Computadora es mediante la aplicación de una operación de convolución bidimensional con diferentes Kernels de convolución.

Convolución Matemática


- En Visión por Computadora o Análisis y Tratamiento de imágenes, es necesario aplicar 'filtros' a las imágenes para resaltar ciertas características.
- Por ejemplo, para detectar bordes horizontales o verticales.



1	1	1
0	0	0
-1	-1	-1

**HORIZONTAL EDGE
DETECTING FILTER**

Convolución Matemática



Convolutional Neural Networks

Redes Neuronales Convolucionales


- **CNN**, Convolutional Neural Networks, o, **ConvNet**.
- Basadas alrededor de la operación de convolución.
- Aplicadas a procesamiento de imágenes.
- Tremendamente exitosas y uno de los motores detrás del auge de DL.

Convolutional Neural Networks


La idea.

- Modificar una MLP de forma que realice una operación de convolución, de una capa a la otra.
- Imitar la misma idea de lo que se observa en la corteza visual, mediante la utilización de la convolución.


Representational Learning




Representational Learning



Representational Learning



Convolutional Neural Network



Convolutional Layer

$$W^{p,q} = [w_{ijk}^{(p,q)}]$$

i : height

j : width, q : Layer

k : depth, p : Filter

$$H^q = [h_{ijk}^q]$$


H : inputlayer

$$h_{ijp}^{(q+1)} = \sum_{r=1}^{Fq} \sum_{s=1}^{Fq} \sum_{k=1}^{d_q} w_{rsk}^{(p,q)} h_{i+r-1,j+s-1,k}^q$$


$$\forall i \in \{1, \dots, Lq - Fq + 1\}$$

$$\forall j \in \{1, \dots, Bq - Fq + 1\}$$


$$\forall p \in \{1, \dots, d_{q+1}\}$$




Convolutional Layer



Convolutional Layer - Feature Maps



Convolutional Layer - Feature Maps



Características

- Stride
- Border Effects

Activation Function - ReLU

Capa ReLU

$$f(x) = x^+ = \max(0, x) \quad (1)$$


$$f(x) = \begin{cases} 0 & x \leq 0 \\ x & x > 0 \end{cases}$$

Pooling Layers

Pooling

- Pooling es similar a un downsampling.
- MaxPooling es la operación más usada. Dada una región de 2×2 , obtener el valor máximo.
- Aportan a la invarianza translacional: no importa dónde se de el máximo, se puede filtrar en la capa siguiente.
- Puede extenderse a hacer otras características invariantes, depende como se agrupen los filtros, y los poolings siguientes.

Pooling Layers - Downsampling




Fully Connected Layer


Fully Connected Layer

- Al final de la Red hay una (o más capas) que se encargan de hacer la clasificación final.
- Softmax: $\sigma(\vec{V})_i = \frac{e^{V_i}}{\sum_{j=1}^K e^{V_j}}$

Convolutional Neural Network



Convolutional Neural Network




Training

Backpropagation

- 1 Supongamos una red para identificar perros, botes y Gokus.
- 2 Red inicializada al azar, igual que siempre.
- 3 Calculamos los valores de salida, capa a capa.
- 4 En las capas *Fully Connected* es exactamente igual que el perceptrón multicapa.
- 5 En las capas de Pooling, solo se actualizan la contribución de los pesos de la salida ganadora (asumiendo una función identidad).
- 6 En las capas convolucionales, hay que mantener los pesos de los filtros en la relación espacial.

Sparse Matrix Representation







Convolutional Neural Network - Success

¿ Por qué funcionan ?

- Matrices esparsas son mucho más eficientes: menos cálculos.
- *Parameter sharing: tied weights*
- *Equivariante* $g(f(x)) = f(g(x))$ Equivariante para la segmentación
- *Invariante* $g(f(x)) = g(x)$ Invariante a la translación
- Jerarquías Espaciales: Ingeniería de Características Jerárquica

Convolutional Neural Network

- Image Recognition
- Object Recognition
- Semantic Segmentation
- Place Recognition
- Image Generation
- Image-to-image translation
- Inpainting






Convolutional Neural Networks

- **Representational Learning**
- **Transfer Learning**
- **xAI**
- **Compositional Architecture**

Representational Learning

Feature Learning



Representational Learning

Feature Learning






Fig. 4. Visualization of the convolutional kernels learned in the first layer of AlexNet.

Transfer Learning



Transfer Learning



Fixed

Free

Compositional Architecture

Arquitecturas y Redes

- Las diferentes combinaciones de capas de convolución, reLU, pooling y fully connected, permiten armar arquitecturas profundas y complejas que intentan solucionar diferentes problemas.
- Como siempre, la elección de la arquitectura correcta no escapa a las generalidades de las redes neuronales. Un poco arte, educated guesses y prueba y error.

Codificación

- (CR) 2P(CR) 2P(CR) 2PF

xAI - Explainable Artificial Intelligence


Inteligibilidad: capacidad del un esquema de ofrecer una representación que permita a un ser humano entender cuál es la característica que el algoritmo identificó para tomar una decisión.

Explicabilidad: capacidad del sistema de explicar el paso a paso, la cadena de razonamiento, que lleva a tomar una decisión particular.


Responsible AI: diseñar sistemas ofreciendo garantías y cotas de funcionamiento, alineándolos con estándares éticos y regulatorios.

AlexNet

- ReLU
- Layer Normalization / Local Response Normalizer
- Dropout Layers
- 2 NVIDIA GTX 580
- Data Augmentation




AlexNet



AlexNet




MNIST handwritten digit dataset




ImageNet Classification Error

Iris 10^2 , ImageNet 5000 images per category, WMT 10^9 total size,

ImageNet Architectures




[9] GoogLeNet Szegedy 2014





[18] MultiGPU ConvNet Krizhevsky 2012


VGG - Visual Geometry Group




DeconvNet



DeconvNet - Transposed Convolution





ResNet




Res-Net Architecture



ResNet




U-Net



U-Net



Convolutional Autoencoder



Convolutional Autoencoder





Figure 8. Visualization of 400 x 400 face images by latent vectors with t-SNE algorithm [20]



CNN Versatility

Dimensions	Singlechannel	Multichannel
1-D	Audio Waveforms	Electroencephalography Motion Capture Markers
2-D	Spectrograms	Color Image
3-D	Computer Tomography	Video

どうもありがとう



Gracias !



- [1] Charu C Aggarwal et al. *Neural networks and deep learning*. Springer, 2018.
- [2] Vincent Dumoulin and Francesco Visin. A guide to convolution arithmetic for deep learning. mar 2016.
- [3] Kunihiro Fukushima and Nobuaki Wake. Handwritten alphanumeric character recognition by the neocognitron. *IEEE transactions on Neural Networks*, 2(3):355–365, 1991.
- [4] Shengli Jiang and Victor M. Zavala. Convolutional Neural Nets: Foundations, Computations, and New Applications. jan 2021.
- [5] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems*, pages 1097–1105, 2012.

- [6] Yann LeCun, Bernhard Boser, John S Denker, Donnie Henderson, Richard E Howard, Wayne Hubbard, and Lawrence D Jackel. Backpropagation applied to handwritten zip code recognition. *Neural computation*, 1(4):541–551, 1989.
- [7] Grace W. Lindsay. Convolutional neural networks as a model of the visual system: Past, present, and future. *Journal of Cognitive Neuroscience*, pages 1–15, Feb 2020.
- [8] Evan Shelhamer, Jonathan Long, and Trevor Darrell. Fully Convolutional Networks for Semantic Segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(4):640–651, nov 2017.