

Variational Autoencoders

TP5 — EJ2 sobre emojis 16x16

Sistemas de Inteligencia Artificial

22 de junio de 2026


ITBA — 2026

Del AE al VAE

- En EJ1 el AE reconstruye bien.
- Pero su latente **no** esta pensado para muestrear.
- Generar desde coordenadas nuevas puede caer en zonas sin estructura.

Idea

El VAE agrega el termino KL para empujar el latente hacia $\mathcal{N}(0, I)$ y volverlo **sampleable**.



El problema y el nuevo dataset

Dataset	emojis.npz
Resolucion	16x16 en grises
Input	256 pixeles
Muestras	960
Clases	16



Pregunta gancho: *podemos aprender un espacio latente desde el cual generar emojis nuevos plausibles?*

Objetivo del EJ2

Aprender un VAE tal que:

$$z \sim \mathcal{N}(0, I) \implies \text{decoder}(z)$$

produzca muestras nuevas que parezcan

Arquitectura base y parametros a estudiar

Encoder variacional + decoder:

$$x \in \mathbb{R}^{256} \rightarrow [256, 64] \rightarrow (\mu, \log \sigma^2)$$

$$z = \mu + \sigma \odot \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I)$$

$$z \rightarrow [64, 256] \rightarrow \hat{x}$$

$$\mathcal{L} = BCE(x, \hat{x}) + \beta KL(q(z | x) \| \mathcal{N}(0, I))$$


- **BCE**: fuerza reconstruccion.
- **KL**: ordena el latente cerca de $\mathcal{N}(0, I)$.
- Esta es la *configuracion base*; despues variamos una pieza a la vez.

Encoder / Decoder	[256, 64] / [64, 256]
Activacion oculta	ReLU
Salida	logistica
Optimizador	Adam
Batch / Epocas	64 / 600
Seed	42
<i>Parametros a elegir</i>	β , <i>latent_dim</i> , recon loss, warmup

Gradient-check del backward:
error relativo max $1,25 \times 10^{-10}$.

Eje 1 — Peso del KL: β -VAE

β -VAE: efecto del peso del KL en el espacio latente



$\beta = 0,1$: mejor reconstruccion, menos regularizacion. $\beta = 4$: latente mas forzado, peor detalle. **Elegimos $\beta = 1$** como compromiso entre reconstruccion y estructura latente.

Eje 2 — Generacion desde el prior


Punto (c) del enunciado

Para generar **no usamos el encoder**.

$$z \sim \mathcal{N}(0, I) \implies \text{decoder}(z)$$


Estas imagenes son **muestras nuevas**, no inputs del dataset.

Muestras nuevas $z \sim \mathcal{N}(0, I)$ decodificadas



Eje 3 — Dentro vs fuera del prior

Extrapolacion del prior: mismos z base escalados antes de decodificar
sigma=1 samplea desde $\mathcal{N}(0, I)$; sigma altos fuerzan extrapolacion del decoder



$\sigma = 1$ samplea desde el prior. Al escalar z con $\sigma = 2$ y 4 nos alejamos de la region donde el decoder fue entrenado por el KL. **La generacion debe evaluarse cerca de $\mathcal{N}(0, I)$.**

Eje 4 — Dimension latente



- 2D: interpretable, pero limitado.
- 8D: gran mejora de reconstrucción.
- 16D: mejora marginal extra.


rec_MSE:

- 2D: 5.27
- 8D: 1.61
- 16D: 1.63

Decision: 2D para visualizar, >2D para capacidad.


Eje extra — BCE vs MSE

VAE emojis (latent=16): BCE más nítida, MSE más borrosa



Dos VAE identicos salvo la loss de reconstruccion. **BCE** queda mas nitida y ademas reconstruye mejor:
rec_MSE 1.38 vs 5.22. **Fijamos BCE.**

Eje extra — ¿memoriza o generaliza?



Split 80/20 por clase.

- Latente 2D underfitea.
- Para 8/16/32 el gap train-test queda acotado.

Gap final:

- 2D: +13.46
- 8D: +4.70
- 16D: +4.73
- 32D: +5.18

Reconstrucción del modelo final

Corrida principal:


- latente 2D
- BCE
- $\beta = 1$
- Adam
- 600 épocas

Final:

- total: 117.995
- rec: 112.219
- KL: 5.776
- rec_MSE: 4.576



Espacio latente 2D




Cada punto es el $\mu(x)$ de un emoji.

- La reconstrucción separa información relevante.
- El KL evita que los códigos se dispersen arbitrariamente.

Lo importante no es separar perfecto, sino que el espacio sea **compacto y sampleable**.


Manifold generativo e interpolación



El decoder aprende una función continua $z \rightarrow \text{imagen}$.
Pequeños movimientos en el latente producen cambios
graduales.

Corrida larga: 600 vs 50k épocas

VAE 16×16 (latente 2D): efecto de entrenar 600 vs 50.000 épocas



Entrenar mas mejora detalle, pero no cambia la conclusion central: el aporte del VAE es **ordenar el latente para poder samplear**.

- Un AE puede reconstruir sin tener un latente generativo.
- El VAE agrega una regularizacion probabilistica via KL.
- Eso permite generar con $z \sim \mathcal{N}(0, I)$.
- β controla el trade-off entre reconstruccion y regularizacion.
- La generacion funciona sobre todo **dentro** de la region del prior.
- Mas dimension latente no siempre implica mas informacion util.